

Demo-odbrana — tok puštanja projekta

Detekcija klikbejt naslova u sportskim vestima na srpskom jeziku

Filip Nikolić (25/3234), Danilo Nikolić (25/3235)

Obrada prirodnih jezika 2025/2026 — ETF

Profesor je tražio da ponesemo **računar sa konfigurisanim projektom** da bismo uporedo prolazili kroz rad. Ovaj dokument je **scenario za to** — predlog hronološkog toka kroz koji bismo vodili demonstraciju: od izvora podataka, preko anotacije i saglasnosti (kappa), do modela i izveštaja. Za svaki korak dat je *cilj*, *komanda* koju puštamo, *očekivani izlaz* i *moгуća pitanja* u tom trenutku.

Pre dolaska — ček-lista

- Laptop sa napunjenom baterijom + punjač; projekat otvoren u editoru (VS Code).
- Virtuelno okruženje radi: `source .venv/bin/activate`.
- `.env` sadrži `ANTHROPIC_API_KEY` (za demo dekodera) — ali bez deljenja ključa na ekranu.
- Internet (za SportKlub API i Claude poziv) — ili pripremljeni keširani rezultati ako mreže nema.
- Otvoreni i PDF-ovi: `izvestaj.pdf`, `Tehnicki-vodic-*.pdf`.
- Podsetnik: enkodori (BERTić/mBERT) traže GPU — *ne* pokrećemo uživo, pokazujemo kod i gotove rezultate iz `results/`.

Sve komande se pokreću iz korena projekta: `/Users/filipjackpot/MasterETF/OPJ`.

1 Korak 0 — Pregled strukture projekta

Cilj: dati profesoru mapu projekta u 1 minut. Otvoriti `docs/Mapa-koda.md` i pokazati četiri faze i gde je šta.

```
ls                               # src/ data/ results/ report/ docs/ ...
```

Šta profesor može pitati ovde

„Objasnite ukratko organizaciju” — pokazati: `src/` (kod po fazama), `data/` (sirovi→anotirani), `results/` (izlazi modela), `report/` (izveštaj). Naglasiti princip: determinizam (seed 42) i razdvojene zavisnosti po fazi.

2 Korak 1 — Izvor podataka (Faza 1)

Cilj: pokazati odakle i kako prikupljamo naslove. Otvoriti `src/scraping/sportklub_api.py` i objasniti WordPress REST API. Po želji uživo povući par naslova (mali broj, da bude brzo):

```
.venv/bin/python src/scraping/sportklub_api.py --broj 20
```

Očekivani izlaz

Ispis „strana 1: ukupno 20” i snimljen CSV u `data/raw/sportklub_api_<datum>.csv` sa kolonama `naslov`, `izvor`, `url`, `datum`, `rubrika`, `datum_scrape`.

Šta profesor može pitati ovde

- „Zašto jedan izvor, a ne tri kao u prijavi?” → da obe klase dolaze sa istog portala pa model uči klikbejt, a ne stil portala.
- „Da li grebete HTML?” → ne, koristimo zvanični REST API (pouzdanije).
- „Koje metapodatke beležite?” → id, URL, datum, rubrika — ispunjen zahtev za URL/identifikator.
- „Kako balansirate skup?” → overscrape + dedup (egzaktna + rapidfuzz) + balansiranje na 1100/1100 (seed 42).

3 Korak 2 — Anotacija i uputstvo (Faza 2)

Cilj: pokazati šemu oznaka i pravila. Otvoriti `annotation/guidelines.md` — mehanizmi KJ/PV/EN/SF, šta NIJE klikbejt, rešeni granični primeri. Pokazati i kako je posao podeljen:

```
# (već urađeno) priprema datoteka za anotaciju, 50/50, kalibracioni skup:
.venv/bin/python src/annotation/make_splits.py
```

Očekivani izlaz

`data/annotated/{filip,danilo}_glavna.csv` + `data/calibration/*_unakrsna.csv`; prvih 110 redova svake polovine su kalibracioni.

Šta profesor može pitati ovde

- „Kako definišete klikbejt?” → četiri mehanizma (KJ/PV/EN/SF), dovoljan jedan; ključni test „znaš li šta se desilo”.
- „Ko je anotirao i da li nezavisno?” → dva člana, kalibracioni skup nezavisno.
- „Pokažite primer spornog naslova” → otvoriti tabelu primera u uputstvu.

4 Korak 3 — Međuanotatorska saglasnost / kappa

Cilj: pustiti uživo izračunavanje Cohen's kappa — pokazuje da je anotacija stvarno rađena i merena.

```
.venv/bin/python src/annotation/iaa.py
```

Očekivani izlaz

```
Kalibracionih parova: 220 / 220
Procentualno slaganje: 82.7%
Cohen's kappa:      0.640    (dobro)
Neslaganja: 38
```

Šta profesor može pitati ovde

- „Zašto kappa, a ne prost procenat?” → kappa skida slaganje slučajem.
- „Vaša kappa je daleko od 0,8 — zašto?” (profesorova primedba!) → klikbejt je subjektivan; pomeraj praga je dosledan/jednosmeran; granica je semantička. *Pokazati matricu konfuzije i listu neslaganja u ispisu.*
- „Koje slučajeve ste teško rešavali i kako?” → tri obrasca (emotivni epitet / teaser / „bomba”+info) + operativna pravila + adjudikacija.

5 Korak 4 — Finalni skup

Cilj: pokazati balansiran skup koji ide u Fazu 3.

```
.venv/bin/python src/annotation/build_dataset.py --po-klasi 1100
.venv/bin/python src/annotation/stats.py
```

Očekivani izlaz

data/annotated/dataset.tsv (1100/1100, naslov\t labela) + statistika (raspodela klasa, prosečne dužine ≈ 9 reči).

Šta profesor može pitati ovde

„Zašto balansiran?“ → uklanja pristrasnost ka većinskoj klasi. „Razdvaja li dužina klase?“ → skoro ne (preklapanje), pa dužina nije signal — razlika je u značenju.

6 Korak 5 — Pretprocesiranje (tokenizacija/stem/lema)

Cilj: uživo demo normalizacije teksta.

```
.venv/bin/python src/preprocessing/serbian.py
```

Očekivani izlaz

Za par primera ispiše `normalize=None` i `normalize=stem` (tokeni razdvojeni razmakom) — vidi se efekat stemovanja.

Šta profesor može pitati ovde

- „Kako tokenizujete?“ → regex (slova+dijakritici+cifre), interpunkcija razdvajač.
- „Razlika stem vs lema?“ → stem = sečenje nastavaka (heuristika); lema = rečnička reč preko `classla` (POS-svesno).
- „Zašto je to bitno za srpski?“ → morfološko bogatstvo, smanjenje rastrkanosti.

7 Korak 6 — Osnovni modeli (Faza 3a)

Cilj: pustiti *brzi* baseline uživo (puni grid traje par minuta, pa za demo koristimo `--quick`).

```
python src/baseline/run_baseline.py --quick
# (ako ima vremena, puni grid:) python src/baseline/run_baseline.py
```

Očekivani izlaz

Tabela po varijanti sa `F1_kb` i `AUC`; puni grid daje najbolje *NB + stem + TF-IDF (1-2)*, $F1 \approx 0,646$, i piše `results/baseline_results.csv`.

Šta profesor može pitati ovde

- „Šta su `C` i `alpha` i kako ih birate?“ → regularizacija / Laplace izgladivanje; log-grid + ugnežđena CV.
- „Šta je ugnežđena unakrsna validacija?“ → spoljna meri, unutrašnja bira hiperparametre — bez curenja.
- „Kako sprečavate curenje pri vektorizaciji?“ → vektorizator se uči unutar fold-a (Pipeline).
- „Zašto je baseline slabiji?“ → vreća reči ne hvata kontekst.

8 Korak 7 — Enkoderski modeli (Faza 3b)

Cilj: objasniti fine-tuning; *ne* pokrećemo uživo (treba GPU), nego pokazujemo kod (`src/transformers/fine`) i *gotove* rezultate.

```
# pokazati rezultate (bez obuke uživo):  
column -t -s, results/encoder_bertic_results.csv | head
```

Očekivani izlaz

Metrike po epohi/fold-u; najbolje BERTić, 3–4 epohe: F1 $\approx$ 0,703, ROC-AUC $\approx$ 0,788.

Šta profesor može pitati ovde

- „Šta je BERT i razlika enkoder/dekoder?” → enkoder razume (maskiranje), dekoder generiše.
- „Zašto BERTić > mBERT?” → mono troši kapacitet na srpski, multi ga deli.
- „Kako birate epohe?” → varirali 2/3/4; 3–4 optimum (kriva učenja).
- „Zašto ne uživo?” → traži GPU; obučavano na Colab-u, ovde pokazujemo kod i rezultate.

9 Korak 8 — Dekoderski model (Faza 3c)

Cilj: pustiti *mali* zero-shot demo na nekoliko naslova (jeftino, brzo).

```
python src/decoder/claude_eval.py --model claude-haiku-4-5 --limit 20
```

Očekivani izlaz

Klasifikacija 20 naslova (0/1), metrike na tom uzorku; rezultati keširani u `results/decoder_cache/`. Pun skup daje F1 $\approx$ 0,715.

Šta profesor može pitati ovde

- „Šta je zero-shot i zašto bez fine-tuninga?” → zatvoren model; meri se sposobnost bez obuke na našim podacima.
- „Kako gradite prompt?” → system traži samo cifru; varijante SR/EN, zero/few, sa/bez definicije.
- „Zašto keširanje i bez temperature?” → ponovljivost, ušteda, determinizam.
- „Zašto nema ROC-AUC?” → vraća tvrdi 0/1 odluku, ne verovatnoću.

10 Korak 9 — Izveštaj (Faza 4)

Cilj: pokazati da se ceo izveštaj generiše iz rezultata i kompajlira.

```
.venv/bin/python src/report/make_tables.py      # results/*.csv -> report/tables/*.tex  
.venv/bin/python src/report/make_figures.py     # -> report/figures/*.png  
cd report && tectonic izvestaj.tex && open izvestaj.pdf
```

Očekivani izlaz

Regenerisane tabele i grafici; `report/izvestaj.pdf` ($\approx$ 10 strana) se otvara sa svim rezultatima.

Šta profesor može pitati ovde

- „Koji je konačni zaključak?” → nema jedinstvenog pobednika: Claude najbolji F1, BERTić najbolja tačnost/AUC; za produkciju BERTić.
- „Koje metrike i zašto F1 na klikbejt klasi?” → to je ciljna klasa; tačnost može biti varljiva.

- „Ograničenja i dalji rad?” → mali skup/jedan domen; few-shot, kalibracija, ansambl, analiza tipova grešaka.

11 Rezervni plan (ako nešto ne radi)

- **Nema interneta:** preskočiti uživo scraping i Claude poziv — pokazati već prikupljene `data/raw/` i keširane `results/decoder_cache/`.
- **Baseline traje predugo:** koristiti `--quick` (3 fold-a, jedna konfiguracija).
- **Enkoderi:** nikad uživo — uvek gotovi CSV-ovi u `results/`.
- **Sve staje:** sve brojke su u `izvestaj.pdf` i u `results/*_izvestaj.md`; demonstraciju voditi kroz njih.

Vidi i: `Pitanja-profesora.pdf` (27 pitanja sa odgovorima), `docs/Komande.md` (sve komande), `Tehnicki-vodic-detalan.pdf` (teorija uz kod).