

Odbrana — moguća pitanja i odgovori

Detekcija klikbejt naslova u sportskim vestima na srpskom jeziku

Filip Nikolić (25/3234), Danilo Nikolić (25/3235)

Obrada prirodnih jezika 2025/2026 — ETF

Ovaj dokument sadrži **27 pitanja** kakva profesor može postaviti na odbrani, sa opširnim odgovorima, poređanih *hronološki* — onako kako teče projekat (od definicije problema i izvora podataka, preko anotacije i saglasnosti, do modela i zaključka). Cilj je da pokaže da smo zaista radili na svakom koraku i da razumemo i *šta* i *zašto* smo uradili.

1 Uvod i definicija problema

Pitanje 1 — Koja je tema i šta tačno rešavate?

Šta je cilj vašeg projekta?

Odgovor. Tema je **binarna klasifikacija sportskih naslova na srpskom jeziku** na dve klase: *klikbejt* (oznaka 1) i *regularan* (oznaka 0). Klikbejt je naslov oblikovan da navede čitaoca na klik manipulacijom, a ne poštenim saopštavanjem vesti. Cilj je da napravimo i *uporedimo* tri porodice modela — klasične linearne klasifikatore, fino podešene enkoderske transformere i dekoderski (generativni) model bez obuke — i utvrdimo koji najbolje hvata suptilni klikbejt. Sport smo izabrali jer se rutinski događaji (transferi, izjave, rezultati) lako pakuju kao senzacija, pa je domen bogat klikbejtom.

Pitanje 2 — Kako definišete klikbejt? Po čemu znate da naslov jeste/nije?

Koje mehanizme manipulacije razlikujete?

Odgovor. Naslov ocenjujemo *sam za sebe*, kako ga čitalac vidi u listi vesti, bez otvaranja članka. Vodeće pitanje: da li naslov *namerno* manipuliše — uskraćivanjem informacije, preuveličavanjem ili veštačkom emocijom. Razlikujemo četiri mehanizma:

- **KJ — kognitivni jaz:** izostavljena ključna informacija („Real ozvaničio veliko pojačanje” — ne kaže koga).
- **PV — preuveličavanje važnosti:** rutinski događaj kao senzacija („Bomba iz Italije” za običan transfer).
- **EN — veštački emocionalni naboj:** napetost/ogorčenje koje ne proizlazi iz vesti („Skandal u Parizu”).
- **SF — senzacionalistička fraza / otvorena forma:** tri tačke, retorička pitanja, „nećete verovati”.

Za oznaku 1 dovoljan je *jedan* mehanizam. Nasuprot tome, uzvičnik, velika slova ili stvarno velika vest rečena direktno *ne* čine klikbejt. Ključni test: ako posle čitanja naslova znaš šta se desilo — verovatno je regularan.

2 Faza 1 — Prikupljanje podataka

Pitanje 3 — Odakle su podaci i zašto samo jedan izvor, kad je u prijavi bilo tri?

U prijavi su bili Mozzart, SportKlub i B92.

Odgovor. Podaci su sa portala **SportKlub**. Svesno smo se opredelili za *jedan* izvor i to obrazložimo: postavka traži jedan tematski domen (sportske vesti), a ne određeni broj izvora. Time što *obe* klase (i klikbejt i regularan) dolaze sa istog portala, model uči stvarni *klikbejt signal*, a ne stil portala. Da smo klikbejt vukli sa jednog, a regularne sa drugog sajta, model bi mogao da nauči da razlikuje portale umesto klikbejta — to bi bila skrivena pristrasnost. Dakle, jedan izvor je ovde metodološki čistiji, a ne lenji izbor.

Pitanje 4 — Kako ste tehnički prikupili naslove?

Da li ste „grebali” HTML?

Odgovor. Nismo parsirali HTML, već smo koristili zvanični **WordPress REST API** portala (`/wp-json/wp/v2/posts`), koji vraća čist naslov, datum i kategorije u JSON-u — pouzdanije od grebanja stranica. Skripta (`src/scraping/sportklub_api.py`) ide stranicu po stranicu (po 100 naslova), uz pauzu između zahteva da ne preoptereći server. Za svaki naslov beležimo metapodatke: jedinstveni id, tekst, izvor, *URL članka*, datum objave, rubriku i datum prikupljanja — čime je ispunjen zahtev da se zabeleži URL/identifikator izvora. Naslovi dolaze sa HTML entitetima (npr. `“`) pa ih dekodiramo.

Pitanje 5 — Koliko ste podataka prikupili i kako ste dobili balansiranih 1100/1100?

Zašto baš balansiran skup?

Odgovor. Namerno smo prikupili *višak* (3000–4000 naslova) da bismo posle anotacije mogli da izbalansiramo skup. Nad sirovim podacima radimo **deduplikaciju**: egzaktnu (identičan tekst) i *približnu* (near-duplicate, biblioteka `rapidfuzz`) da uklonimo gotovo iste naslove. Finalni skup je balansiran na **2200 naslova (1100 klikbejt / 1100 regularan)**, deterministički (seed 42), sačuvan kao `dataset.tsv`. Balansiranje uklanjanja pristrasnost klasifikatora ka većinskoj klasi i pojednostavljuje tumačenje metrika (npr. tačnost od 50 % je slučaj, sve iznad je signal).

3 Faza 2 — Anotacija i saglasnost

Pitanje 6 — Ko je anotirao i kako ste podelili posao?

Kako ste obezbedili da merite saglasnost?

Odgovor. Anotirala su *dva* člana tima, nezavisno. Skup smo podelili tačno na pola (deterministički, seed 42). Da bismo mogli da izmerimo saglasnost, izdvojili smo **kalibracioni skup od 220 naslova** (po 110 iz svake polovine) koje su anotirala *oba* člana — pa za tih 220 imamo dve nezavisne oznake i možemo da uporedimo. Anotaciju vodi pisano uputstvo (`annotation/guidelines.md`) sa definicijama mehanizama i rešenim graničnim primerima.

Pitanje 7 — Šta je međuanotatorska saglasnost i zašto kappa, a ne prost procenat slaganja?

Odgovor. Međuanotatorska saglasnost meri koliko se dva anotatora slažu — pokazatelj da je zadatak dobro definisan i oznake pouzdane. Koristimo **Cohen’s kappa** jer *prost procenat slaganja precenjuje* kvalitet: ako oba anotatora često biraju istu klasu, slučajno će se složiti i bez ikakvog „znanja”. Kappa oduzima to *očekivano slaganje slučajem* (P_e) i normira ostatak: $\kappa = \frac{P_o - P_e}{1 - P_e}$. Tako

$\kappa = 1$ je savršeno slaganje, $\kappa = 0$ je „kao slučaj”. Kappa je standard upravo zato što meri slaganje koje se *ne može* objasniti pukom raspodelom klasa.

Pitanje 8 — Kolika je vaša kappa i kako je tumačite?

Odgovor. Postigli smo $\kappa = 0,640$ (procentualno slaganje 82,7 %, tj. 182/220). Po Landis–Kohovoj skali to je opseg „značajne/dobre” saglasnosti (0,61–0,80) i prelazi našu internu ciljanu granicu $\kappa \geq 0,6$. Brojku prijavljujemo kao meru *nezavisne* saglasnosti, pre adjudikacije.

Pitanje 9 — Vaša kappa je prihvatljiva, ali daleko od idealne; za binarne oznake sve ispod 0,8 nije sjajno. Zašto?

Ovo je profesorova konkretna primedba.

Odgovor. Slažemo se — 0,640 je dobar, ali ne idealan rezultat, i to je posledica *suštine zadatka*, a ne nemarne anotacije. Tri razloga: (1) **Klikbejt je inherentno subjektivan, gradijentan pojam** — granica između „živopisnog” i „manipulativnog” naslova je kontinuum; i u literaturi se za klikbejt prijavljuje umerena saglasnost. (2) **Pomeraaj praga je dosledan i jednosmeran:** u 25 od 38 neslaganja (66 %) jedan anotator vidi klikbejt tamo gde drugi vidi regularan, i to u *istom* smeru — jedan je sistematski blaži prag. Da je neslaganje bilo nasumično, kappa bi bila mnogo niža; ovako se razlaz svodi na kalibraciju *jednog* praga. (3) **Granica je semantička, ne površinska** — slažemo se na svim jasnim slučajevima, a razilazimo se samo na suptilnom, „blago senzacionalnom” sloju, gde i ljudski sud prirodno varira.

Pitanje 10 — Na koje ste konkretne problematične slučajeve nailazili i kako ste ih rešavali?

Odgovor. Izdvojili smo tri ponavljajuća sporna obrasca i za svaki uveli *operativno pravilo* (upisano u uputstvo):

1. **Emotivni epitet bez tvrde manipulacije** („Sedmica za istoriju”, „Siner šokantno ispao”, „Kakva golčinal”). Pravilo: epitet *sam po sebi* nije dovoljan za oznaku 1 — mora ga pratiti preuveličavanje (PV) ili uskraćivanje (KJ); inače je 0.
2. **Najava „otkrića” / teaser** („Lazić otkrio: čuo sam da me je Dule želeo”). Pravilo: teaser je klikbejt *samo ako* namerno uskraćuje ključnu informaciju; ako je suština prisutna — 0.
3. **„Bomba/Šok/Skandal” + delom data informacija** („Bomba: Dida odlazi u KTM”). Pravilo: ako je vest stvarno velika i suština rečena — 0; ako je preuveličavanje očigledno — 1. Test: da li je emocija *veštačka*.

Dodali smo i konvencije: prefiksi (VIDEO)/(FOTO) su neutralni; uzvičnik i velika slova sami po sebi nisu klikbejt.

Pitanje 11 — Kako ste rešili neslaganja u finalnom skupu?

Odgovor. Spornih (preklapajućih) naslova iz kalibracije bilo je 38 i njih smo rešili **adjudikacijom** — kroz zajedničku diskusiju usaglasili smo labelu koja je ušla u finalni skup. Zato je finalni skup *kvalitetniji* od same brojke $\kappa = 0,640$: ta brojka opisuje *nezavisnu* saglasnost pre dogovora, a u finalni skup su sva neslaganja naknadno razrešena konsenzusom.

4 Pretprocesiranje teksta

Pitanje 12 — Kako radite tokenizaciju teksta?

Odgovor. Pre tokenizacije tekst Unicode-normalizujemo (NFC), transliterujemo eventualnu ćirilicu u latinicu i prevodimo u mala slova. Zatim **tokenizujemo** regularnim izrazom: token je

neprekinut niz *slova* (uključujući srpske dijakritike *ž ć č đ š*) i *cifara*; interpunkcija i razmaci su razdvajajući i podrazumevano se uklanjaju. Npr. „Partizan pobedio 2:1!” → [partizan, pobedio, 2, 1]. Vektorizator (*scikit-learn*) dobija već tokenizovan tekst i samo deli po razmaku, pa ne tokenizuje dvaput.

Pitanje 13 — Šta je stemovanje i kako ste ga implementirali?

Odgovor. Stemovanje svodi reč na *osnovu* mehaničkim sečenjem nastavaka (osnova ne mora biti prava reč). Napisali smo **lagani heuristički stemer bez zavisnosti**: imamo listu poznatih srpskih nastavaka (imenički, pridevski, glagolski), sortiranu od najdužeg ka najkraćem, i za token uklanjamo prvi nastavak koji se poklopi (pohlepno, *longest-match*), uz zaštitu da osnova ne padne ispod 3 slova i da se cifre ne diraju. Cilj je morfološka normalizacija: „pobeda/pobede/pobedom” → ista osnova, čime se smanjuje raštrkanost vokabulara (srpski je morfološki bogat).

Pitanje 14 — Šta je lematizacija i po čemu se razlikuje od stemovanja?

Odgovor. Lematizacija takođe svodi reč na osnovni oblik, ali na **lemu** — pravu rečničku reč — koristeći gramatičko znanje (vrstu reči, POS). Za to koristimo biblioteku **classla** sa modelom za srpski (procesori `tokenize, pos, lemma`). Razlika: stem je brza heuristika koja može pogrešiti i daje osnovu koja ne mora biti reč; lematizacija je morfološki ispravna, hvata i nepravilne oblike (npr. „najbolji” → „dobar”, „igrača” → „igrač”), ali traži model i sporija je. Obe tretiramo kao *varijantu* i empirijski poredimo.

Pitanje 15 — Zašto je normalizacija reči bitna baš za srpski?

Odgovor. Klasični modeli vide tekst kao *vreću reči*, gde je svaka reč zasebno obeležje. Srpski ima izraženu fleksiju (padeži, rod, broj, vremena), pa isti pojam ima desetine oblika. Bez normalizacije model svaki oblik uči zasebno, signal se *raspršuje* po mnogo retkih kolona i brzo ponestane primera po obeležju (problem retkosti). Stemovanje i lematizacija sažimaju oblike u jednu osnovu — manje dimenzija, gušća obeležja, bolja generalizacija.

5 Faza 3a — Osnovni modeli

Pitanje 16 — Koje osnovne modele koristite i zašto baš njih?

Odgovor. Koristimo **multinomijalni naivni Bajes** i **logističku regresiju**. Naivni Bajes je verovatnosni klasifikator koji pretpostavlja nezavisnost reči (otud „naivni”); brz je i jak na kratkom tekstu, klasičan baseline za klasifikaciju. Logistička regresija je linearni model koji uči težinu svake reči i daje dobro kalibrisane verovatnoće, bez pretpostavke nezavisnosti. Dva komplementarna pristupa daju pošteniju „donju granicu” koju transformeri treba da nadmaše.

Pitanje 17 — Šta su TF, IDF i TF-IDF i zašto ih poredite?

Odgovor. To su sheme *ponderisanja* reči. **TF** (term frequency) = koliko se reč javlja u naslovu. **IDF** (inverse document frequency, $\log(N/df)$) = reč koja je u skoro svakom naslovu („je”, „u”) nosi malo informacije i dobija malu težinu, a retka/specifična reč veliku. **TF-IDF** = $TF \times IDF$, visoko vrednuje reč *čestu u ovom naslovu* a *retku u korpusu* (diskriminativnu). Poredimo ih jer na *kratkim* naslovima reči se retko ponavljaju, pa $TF \approx$ prisustvo — hteli smo empirijski da vidimo koliko IDF i sublinearno skaliranje uopšte pomažu (pokazalo se: malo, razlike su male).

Pitanje 18 — Šta su hiperparametri C i alpha i kako ste ih birali?

Ovo je čest „dublji” pitanje.

Odgovor. **C (logistička regresija)** kontroliše *regularizaciju* — kaznu za prevelike težine. Malo $C \Rightarrow$ jaka kazna $\Rightarrow$ jednostavniji model, manje preprilagođavanja, ali rizik od podprilagođavanja; veliko $C \Rightarrow$ slaba kazna $\Rightarrow$ model se pripije uz trening (overfitting). **alpha (naivni Bajes)** je *Laplace/aditivno izgladivanje*: dodaje malu pseudo-frekvenciju svakoj reči da nijedna verovatnoća ne bude nula (jer bi jedna nula poništila ceo proizvod verovatnoća). Oba biramo *validacijom*, tražeći po *log-skali* ($C \in \{0,01 \dots 100\}$, $\alpha \in \{0,01 \dots 2\}$) jer im je efekat multiplikativan — korak $\times 10$ pokriva prostor efikasnije od $+1$. Izbor radi unutrašnja petlja ugneždene unakrsne validacije.

Pitanje 19 — Šta je unakrsna validacija i zašto baš ugneždjena (nested)?

Odgovor. **Unakrsna validacija** deli skup na 10 delova; 10 puta trenira na 9 a testira na 1, pa usredniti — tako se meri na svim podacima, ne na jednom srećnom razdvajanju. **Stratifikovana** je da svaki fold čuva odnos klasa 50/50. **Ugneždjena** je da bismo *pošteno* izveštavali: hiperparametre bira *unutrašnja* petlja samo na trening delu, a *spoljna* petlja ocenjuje na fold-u koji pri izboru nije viđen. Da koristimo jednu petlju za izbor i izveštaj, „provirili” bismo u test i dobili lažno bolji rezultat.

Pitanje 20 — Kako sprečavate curenje informacija pri pretprocesiranju?

Odgovor. Stemovanje i lematizacija su *deterministički po tokenu* (ne uče se iz podataka), pa ih radimo jednom nad celim skupom bez rizika. Ono što *jeste* naučeno — vokabular i IDF težine vektorizatora — stavili smo unutar Pipeline-a, pa se uče *isključivo* na trening delu svakog fold-a, nikad na test delu. Tako test fold ostaje zaista neviđen.

Pitanje 21 — Koji je najbolji baseline rezultat i šta iz njega zaključujete?

Odgovor. Najbolja varijanta je **naivni Bajes + stemovanje + TF-IDF (1–2 grami)**, sa F1 na klikbejt klasi $\approx 0,646$ i ROC-AUC $\approx 0,676$. Stemovanje pomaže (smanjuje morfološku raštrkanost), dok IDF i bigrami donose tek malo. Glavni zaključak: vreća reči hvata površinske leksičke obrasce, ali teško prepoznaje suptilni klikbejt koji zavisi od konteksta — što motiviše prelazak na kontekstualne modele.

6 Faza 3b — Enkoderski modeli

Pitanje 22 — Šta je BERT, koja je razlika enkoder/dekoder i šta je fine-tuning?

Odgovor. **Transformer** preko mehanizma *pažnje* za svaku reč gleda kontekst, pa ista reč dobija različitu reprezentaciju zavisno od okoline (kontekstualni model). **Enkoder** (BERT) je predtreniran da *razume* tekst — uči pogađajući zamaskiranu reč gledajući i levo i desno — i idealan je za klasifikaciju. **Dekoder** (GPT, Claude) je predtreniran da *generiše* (predviđa sledeću reč). **Fine-tuning** je kratko doučavanje već predtreniranog modela na našem malom označenom skupu, da opšte jezičko znanje usmerimo baš na klikbejt — mnogo bolje nego učiti od nule.

Pitanje 23 — Zašto je BERTić bolji od mBERT-a?

Odgovor. **BERTić** je monolingvalni model, treniran na srpskom i srodnim (BCMS) jezicima, pa sav kapacitet troši na njih i bolje hvata jezičke nijanse. **mBERT** je višejezični — isti kapacitet deli na 100+ jezika — pa je „rastegnut”. Zato BERTić nadmašuje mBERT na svim metrikama (F1

$\approx 0,703$, ROC-AUC do 0,788 naspram mBERT-ovih nešto nižih), što potvrđuje vrednost jezički specijalizovanog modela.

Pitanje 24 — Kako birate broj epoha za fine-tuning?

Odgovor. Broj epoha je koliko puta model prođe ceo trening skup. Premalo $\Rightarrow$ ne nauči (podprilagođavanje); previše $\Rightarrow$ zapamti trening (overfitting). Zato smo *varirali* 2/3/4 epohe i merili: 2 epohe su nedovoljne, dok 3–4 daju najbolji i stabilan rezultat (kriva učenja se izravna), pa dalje obučavanje ne donosi dobitak.

7 Faza 3c — Dekoderski model

Pitanje 25 — Kako ste koristili Claude, šta znači zero-shot i zašto bez fine-tuninga?

Odgovor. Claude (Haiku) je zatvoreni dekoderski model dostupan preko API-ja; ne možemo (ni ne treba) da ga fino podešavamo, pa ga koristimo u režimu **zero-shot** — damo mu samo zadatak i definiciju klikbejta, *bez ijednog* rešenog primera, i tražimo da odgovori samo cifrom 0/1. On se oslanja na znanje iz predtreniranja. To je i poenta poređenja: koliko model *bez ikakve obuke na našim podacima* može da postigne. (U prijavi je naveden ChatGPT; postavka dozvoljava i druge dekoderske modele, pa smo uzeli Claude kao funkcionalno ekvivalentan.)

Pitanje 26 — Koje prompt varijante ste poredili i kako ste sprečili nepouzdanost?

Odgovor. Poredili smo varijante po tri ose: *jezik* prompta (srpski/engleski), *format* (zero-shot vs few-shot) i *sa/bez definicije* klikbejta. Razlika SR vs EN je zanemarljiva (F1 0,710 vs 0,715). Pouzdanost smo obezbedili tako što: sistemski prompt traži *samo cifru* (lako parsiranje), `max_tokens` je mali (jeftino), ne koristimo *temperature* (deterministički odgovor), a sve odgovore *kešujemo* (prekid/nastavak bez dvostrukog plaćanja). Few-shot primere izuzimamo iz evaluacije (holdout) da ne bi „procurili”.

8 Poređenje, zaključak i ograničenja

Pitanje 27 — Koji je model najbolji? Koja su ograničenja i šta biste dalje radili?

Odgovor. Nema jedinstvenog pobednika — i to je glavni nalaz. Po *F1 na klikbejt klasi* vodi dekoderski Claude (0,715), ali po *tačnosti* i kalibrisanim verovatnoćama (ROC-AUC) najbolji je BERTić (0,704 / 0,788). Dekoder je najbolji *kada nema podataka za obuku*; enkoder kada trebaju pouzdane verovatnoće i lokalno, besplatno izvršavanje. Za produkciju preporučujemo BERTić (mali, besplatan, lokalan, kalibrisan). **Metriku F1 na klikbejt klasi** naglašavamo jer je to klasa koju želimo da detektujemo, a sama tačnost može biti varljiva. **Ograničenja:** skup je relativno mali (2200), iz jednog domena i izvora; dekodera daje samo tvrde 0/1 odluke (bez AUC-a); evaluirane su dve glavne prompt varijante. **Dalji rad:** više domena i izvora, veći skup, few-shot i kalibracija dekodera, ansambl (BERTić + dekodera) i analiza tipova grešaka po podtipovima klikbejta (KJ/PV/EN/SF).