

Detekcija klikbejt naslova u sportskim vestima na srpskom jeziku

Filip Nikoli (25/3234)

Danilo Nikoli (25/3235)

Obrada prirodnih jezika 2025/2026 — Elektrotehniki fakultet

Saetak

Rad se bavi binarnom klasifikacijom sportskih naslova na srpskom jeziku na *klikbejt* i *regularne*. Skup od 2200 naslova (1100/1100) prikupljen je sa jednog izvora (portal SportKlub) i nezavisno anotiran od dva lana tima, uz meuanotatorsku saglasnost Cohen's $\kappa = 0,640$. Uporeena su tri tipa pristupa: osnovni modeli (logistika regresija i naivni Bajes nad TF/IDF/TF-IDF obelejima), enkoderski jeziki modeli (monolingvalni BERTi i viejezini mBERT, fino podeeni) i dekoderski jeziki model (Claude, bez fino podeavanja, zero-shot). Svi modeli su nadmaili osnovnu liniju; najbolju ukupnu tanost i kalibrisane verovatnoe dao je BERTi (tanost 0,704, ROC-AUC 0,788), dok je dekoderski model bez ijednog primera za obuku postigao najvii F1 na klikbejt klasi (0,715). Rezultati pokazuju da kontekstualni modeli znatno bolje hvataju suptilni klikbejt od pristupa zasnovanih na vrei rei.

Sadraj

1	Uvod	2
1.1	Definicija klikbejta	2
2	Faza 1 — Prikupljanje podataka	2
3	Faza 2 — Anotacija podataka	3
3.1	ema oznaka	3
3.2	Uputstvo za anotaciju	3
3.3	Kalibracija i meuanotatorska saglasnost (IAA)	3
3.4	Tumaenje saglasnosti	3
3.5	Problematici sluajevi i njihovo reavanje	4
3.6	Glavna anotacija	4
4	Deskriptivna statistika skupa	5
4.1	Raspodela klasa i duina naslova	5
5	Faza 3 — Obuavanje i evaluacija modela	5
5.1	Protokol evaluacije	5
5.2	Pretprocesiranje teksta: tokenizacija, stemovanje, lematizacija	5
5.3	Osnovni modeli (LR + Naivni Bajes)	6
5.4	Enkoderski LLM (BERTi + mBERT)	7
5.5	Dekoderski LLM (Claude)	8
5.6	Uporedni pregled svih modela	8
6	Zakljuak	9

1 Uvod

Klikbejt (engl. *clickbait*) je naslov koji je oblikovan tako da navede itaoca na klik manipulacijom, a ne potenim saoptavanjem vesti [7, 2]. U sportskom novinarstvu je posebno est jer se rutinski dogaaji (transferi, izjave, rezultati) lako pakuju kao senzacija. Cilj ovog projekta je **binarna klasifikacija** sportskih naslova na klikbejt (oznaka 1) i regularne (oznaka 0), uz uporednu analizu tri porodice modela: klasinih linearnih klasifikatora, fino podeenih enkoderskih transformera i dekoderskog (generativnog) jezikog modela u reimu bez obuke. Rad prati etiri faze: prikupljanje podataka, anotaciju, obuavanje i evaluaciju modela, te dokumentaciju. U nastavku se opisuje svaka faza, daje deskriptivna statistika skupa i uporedna analiza rezultata.¹

1.1 Definicija klikbejta

Naslov ocenjujemo *sam za sebe*, onako kako ga italac vidi u listi vesti, bez otvaranja lanka. Vodee pitanje je: da li naslov *namerno* manipulier itaoce da klikne — uskraivanjem informacije, preuveličavanjem ili vetakom emocijom — umesto da poteno saopti vest. Razlikujemo etiri mehanizma manipulacije:

- **(KJ) Kognitivni jaz** — namerno izostavljanje kljune informacije (ko/ta/koliko/ishod), npr. „Real ozvaniio veliko pojaanje” (ne kae koga).
- **(PV) Preuveličavanje vanosti** — rutinski dogaaj predstavljen kao senzacija, npr. „Bomba iz Italije” za obian transfer.
- **(EN) Vetaki emocionalni naboj** — napetost ili ogorenje koje ne proizilazi iz vesti, npr. „Skandal u Parizu”.
- **(SF) Senzacionalistika fraza / otvorena forma** — nedovrene reenice s tri take, retorika pitanja, „neete verovati”.

Za oznaku 1 dovoljan je jedan mehanizam. Naprotiv, uzvinik, velika slova ili stvarno velika vest reena direktno („Real ozvaniio Mbapea”) *ne* ine naslov klikbejtom. Kljuni test: ako posle itanja naslova zna ta se desilo, naslov je verovatno regularan.

2 Faza 1 — Prikupljanje podataka

Izvor. Podaci su prikupljeni sa portala **SportKlub** preko njegovog WordPress REST API-ja (arhiva od oko 449 000 lanaka). U prijavi su pomenuta tri izvora (Mozzart Sport, SportKlub, B92), ali smo se opredelili za *jedan* izvor. Postavka zahteva jedan tematski domen (sportske vesti), a ne odreeni broj izvora; time to obe klase (klikbejt i regularan) dolaze sa istog portala, model ui stvarni klikbejt signal, a ne stil portala. Ovo je svesno odstupanje od prijave i ovde se eksplicitno obrazlae.

Tehnika i metapodaci. Naslovi su povueni programski preko REST API-ja (uz `requests` i ograniavanje uestalosti zahteva). Za svaki naslov belee se metapodaci: jedinstveni `id`, tekst naslova (UTF-8), izvor, puni `url` lanka, datum objave, rubrika i datum prikupljanja. Time je ispunjen zahtev da se zabelei URL/jedinstveni identifikator izvora.

ijenje i deduplikacija. Sirovo je prikupljen viak (3000–4000 naslova) da bi se posle anotacije mogao izbalansirati skup. Sprovedena je egzaktna deduplikacija (identian tekst) i priblina deduplikacija (engl. *near-duplicate*, uz `rapidfuzz`) radi uklanjanja gotovo istih naslova. Finalni skup za Fazu 3 je balansiran na **2200 naslova (1100 klikbejt / 1100 regularan)**, sauvan u UTF-8 tekstualnom formatu `dataset.tsv` (kolone `naslov` → `labela`). Format TSV je standardni UTF-8 tekstualni format za klasifikaciju teksta i odgovara zahtevu za „UTF-8 TXT”.

¹Projekat radi dvolana grupa, uz izriito odobrenje predavaa za rad u paru.

3 Faza 2 — Anotacija podataka

3.1 ema oznaka

Svatom naslovu dodeljuje se jedna binarna oznaka: 1 (klikbejt) ili 0 (regularan). Mehanizmi manipulacije (KJ/PV/EN/SF) korieni su kao pomo pri odluivanju; pod-tipovi su opcioni i nisu sistematski unoeni u finalni skup.

3.2 Uputstvo za anotaciju

Uputstvo (`annotation/guidelines.md`) definie svaki mehanizam, navodi ta *nije* klikbejt (uzvinik, velika slova, velika vest reena direktno, informativni citati, rezultati i izvetaji sa jasnim sadrajem) i daje reene granine primere. Naslov se uvek ocenjuje izolovano, bez otvaranja lanka.

3.3 Kalibracija i meuanotatorska saglasnost (IAA)

Pre glavne anotacije, oba anotatora su *nezavisno* oznaila kalibracioni skup od 220 naslova radi merenja saglasnosti. Kao mera korien je Cohen's κ (prikladan za dva anotatora; sa dva lana postoji jedan par, pa je grupni prosek jednak tom paru). Rezultati su u Tabeli 1.

Tabela 1: Meuanotatorska saglasnost na kalibracionom skupu.

Mera	Vrednost
Kalibracionih parova	220 / 220
Procentualno slaganje (P_o)	82,7 % (182/220)
Cohen's kappa	0,640
Neslaganja	38 / 220 (17,3 %)

Matrica neslaganja (Filip $\times$ Danilo) data je u Tabeli 2.

Tabela 2: Matrica slaganja anotatora na kalibracionom skupu (220 naslova).

	Danilo = 0	Danilo = 1	Σ Filip
Filip = 0	114	13	127
Filip = 1	25	68	93
Σ Danilo	139	81	220

3.4 Tumaenje saglasnosti

Po Landis–Kohovoj skali $\kappa = 0,640$ spada u opseg „znaajne” (engl. *substantial*, 0,61–0,80) saglasnosti i prelazi nau internu ciljanu granicu $\kappa \geq 0,6$. Svesni smo, meutim, da za *binarne* oznake u produkcionim primenama tek $\kappa \geq 0,8$ predstavlja zaista pouzdanu saglasnost; na rezultat treba itati kao *dobar*, *ali ne idealan*. Smatramo da je ovaj nivo posledica sutinske osobine zadatka, a ne nemarne anotacije, iz tri razloga:

- **Klikbejt je inherentno subjektivan, gradijentan pojam.** Granica izmeu „ivopisnog” i „manipulativnog” naslova je kontinuum, a ne otra linija; i u literaturi se za klikbejt prijavljuje umerena saglasnost.
- **Pomeraj praga je dosledan i jednosmeran**, to je vidljivo iz Tabele 2: u **25 od 38** neslaganja (66 %) Filip vidi klikbejt tamo gde Danilo vidi regularan naslov (a ne nasumino u oba smeru). Filip je sistematski blai prag (93/220 klikbejt naspram Danilovih 81/220)

— razlaz je u *kalibraciji jednog praga*, ne u nerazumevanju pojma. Da je neslaganje bilo nasumino, κ bi bila znatno nia.

- **Granica je semantika, ne povrinska.** Anotatori se slau na jasnim sluajevima (jednomislili su o 182/220), a razilaze iskljuivo na suptilnom, „blago senzacionalnom” sloju, gde i ljudski sud prirodno varira.

3.5 Problematini sluajevi i njihovo reavanje

Analizom 38 neslaganja izdvojili smo tri ponavljajua obrasca koji su pravili najvie problema. Za svaki je, posle zajednike diskusije, uvedeno *operativno pravilo* koje je upisano u uputstvo (`annotation/guidelines.md`, odeljak 4–5) i primenjeno u glavnoj anotaciji (Tabela 3).

Tabela 3: Tipovi spornih sluajeva i usvojena pravila odluivanja.

Obrazac	Primer (Filip=1 / Danilo=0)	Usvojeno pravilo
Emotivni / senzacionalni epitet bez tvrde manipulacije	„Sedmica za istoriju”, „Siner okantno ispao”, „Kakva golina!”	Epitet sam po sebi nije dovoljan za oznaku 1; mora biti praen preuveličavanjem (PV) ili uskraivanjem informacije (KJ). Inae $\rightarrow 0$.
Najava „otkria” / teaser (KJ?)	„Lazi otkrio: uo sam da me je Du-le eleo”	Teaser je klikbejt samo ako naslov namerno uskrauje kljunu informaciju koja se mogla navesti. Ako je sutina ipak prisutna $\rightarrow 0$.
„Bomba / ok / Skandal” + (de-lom) data informacija	„Bomba: Dia odlazi u KTM”	Ako je vest stvarno velika i sutina reena $\rightarrow 0$; ako je preuveličavanje oigledno (rutinski dogaaj) $\rightarrow 1$. Test: da li je emocija <i>vetaka</i> .


Pored ovih pravila, usaglaene su i dve tehnike konvencije koje su uklonile deo neslaganja: prefiksi (VIDEO)/(FOTO) tretiraju se kao *neutralni* (ne utiu na oznaku), a uzvinik i velika slova *sami po sebi* nisu klikbejt ako naslov i dalje poteno prenosi vest. Granini primeri iz Tabele 3 ostavljeni su u uputstvu kao referentni reeni sluajevi, da bi anotacija ostala konzistentna.

3.6 Glavna anotacija

Posle kalibracije i usvajanja gornjih pravila, preostali naslovi su podeljeni na pola i anotirani jednostruko. Preklapajui (sporni) naslovi iz kalibracije reeni su *adjudikacijom* — kroz zajedniku diskusiju usaglaena labela ula je u finalni skup. Vrednost $\kappa = 0,640$ prijavljuje se kao mera *nezavisne* saglasnosti (pre adjudikacije); finalni skup je, dakle, kvalitetniji od te brojke jer su sva neslaganja naknadno razreena konsenzusom.

4 Deskriptivna statistika skupa

4.1 Raspodela klasa i duina naslova



Slika 1: Levo: raspodela klasa. Desno: duina naslova (rei) po klasi.

Finalni skup za obuku je namerno balansiran (1100/1100), ime se uklanja pristrasnost klasifikatora prema veinskoj klasi i pojednostavljuje tumaenje metrika. Duina naslova slabo razdvaja klase: klikbejt naslovi su u proseku tek neznatno dui (proseno 9,0 rei / 55,2 karaktera) od regularnih (8,4 rei / 53,3 karaktera). Praktino preklapanje raspodela duina znai da puka duina nije koristan signal — razlika je u *znaenju i formi*, a ne u broju rei, to je u skladu sa slabim rezultatima modela zasnovanih na vre rei (Odeljak 5.3). Po rubrikama su obe klase ravnomerno zastupljene (fudbal, Evroliga, Rolan Garos, Superliga, ABA liga...), pa rubrika nije izvor pristrasnosti.

5 Faza 3 — Obuavanje i evaluacija modela

5.1 Protokol evaluacije

Osnovni i enkoderski modeli ocenjeni su **10-strukom stratifikovanom unakrsnom validacijom**; za osnovne modele hiperparametri su birani *ugneenom* unakrsnom validacijom (engl. *nested CV*) da bi se izbeglo curenje informacija. Da bi ocena bila potena, pretprocesiranje (stemovanje/lematizacija) radi se nad celim skupom, ali se vektorizator (vokabular i IDF teine) ui *unutar svakog fold-a*. Dekoderski model ocenjen je nad celim skupom (2200). Za sve modele izvetavaju se iste metrike: tanost, preciznost/odziv/F1 sa fokusom na klikbejt klasu, makro-F1 i ROC-AUC (gde model daje verovatnoe).

5.2 Pretprocesiranje teksta: tokenizacija, stemovanje, lematizacija

Pre vektorizacije, svaki naslov prolazi kroz lanac normalizacije implementiran u `src/preprocessing/serbia`. Detaljan opis svake tehnike sa primerima dat je u prateem dokumentu `docs/Obrada-teksta.md`; ovde se saima ta je primenjeno.

Osnovna normalizacija. Tekst se Unicode-normalizuje (NFC), irilica se transliteruje u latinicu (SportKlub je latinini, ali radi robusnosti) i prevodi u mala slova. Time se „Zvezda” i „ZVEZDA” svode na isti token.

Tokenizacija. Naslov se deli na tokene regularnim izrazom koji kao token prepoznaje neprekinut niz slova (ukljuujui srpske dijakritike) i cifara; interpunkcija i razmaci su *razdvajai* i podrazumevano se uklanjaju (opciono se mogu zadržati kao zasebni tokeni). Tako npr. „Partizan

pobedio 2:1!” daje tokene [partizan, pobedio, 2, 1]. Vektorizator (`scikit-learn`) dobija ve tokenizovan, razmakom razdvojen niz, pa samo deli po razmaku (`token_pattern=\S+`); n -grami (1–1 i 1–2) i prag `min_df=2` primenjuju se nad tim tokenima.

Stemovanje. Koristi se *lagani heuristiki stemer* (suffix-stripping) napisan bez spoljnih zavisnosti: za svaki token se pohlepno (najdui-prvi) uklanja najdui poznati srpski nastavak (imeniki padei, pridevski/komparativni i glagolski nastavci), uz zatitu da se osnova ne skрати ispod tri slova i da se cifre ne diraju. Cilj je morfoloka normalizacija — „pobedi”, „pobeda”, „pobedom” → ista osnova — ime se smanjuje ratrkanost vokabulara (srpski je morfoloki bogat). Pristup je svesno jednostavan i transparentan: ne zamenjuje pravi morfoloki analizador, ali je dovoljan kao baseline-varijanta i nije skup.

Lematizacija. Kao tanija alternativa stemovanju koristi se biblioteka `classla` [4] sa modelom za srpski i procesorima `tokenize, pos, lemma`. Za razliku od stemera, lematizacija je *morfoloki ispravna* i POS-svesna: vraa reniku osnovu (lemu) rei („igraa” → „igra”, „najbolji” → „dobar”), ali zahteva preuzimanje modela i sporija je. Tri varijante normalizacije (`none` / `stem` / `lemma`) tretiraju se kao hiperparametar iji se efekat meri u baseline gridu (Odeljak 5.3).

Napomena o curenju informacija. Poto su stemovanje i lematizacija deterministiki po tokenu (ne ue se iz podataka), pretprocesiranje se radi *jednom* nad celim skupom; vokabular i IDF teine vektorizatora i dalje se ue iskljuivo *unutar svakog fold-a*, pa nema curenja informacija u unakrsnoj validaciji. Stop-rei se, po preporuci profesora, *ne* izbacuju.

5.3 Osnovni modeli (LR + Naivni Bajes)

Ispitan je grid varijanti: pretprocesiranje (bez / heuristiki stemer / lematizacija, vidi Odeljak 5.2), ponderisanje obeleja (TF / IDF / TF-IDF / puko brojanje) i opseg n -grama (1–1, 1–2). Implementacija se oslanja na `scikit-learn` [6].

Tabela 4: Osnovni modeli — efekat preprocessinga i odlika.

Model	Norm.	ema	n-gram	$F1_{kb}$	Acc.	AUC
mnb	stem	tfidf	1-2	0.646±0.045	0.622±0.050	0.676±0.059
mnb	stem	bow	1-2	0.642±0.048	0.625±0.050	0.678±0.060
mnb	stem	tf	1-2	0.642±0.045	0.622±0.047	0.677±0.059
mnb	stem	tf	1-1	0.641±0.050	0.624±0.051	0.682±0.060
mnb	lemma	tf	1-2	0.641±0.038	0.632±0.038	0.686±0.051
mnb	lemma	bow	1-2	0.638±0.034	0.631±0.032	0.681±0.052
mnb	lemma	tf	1-1	0.637±0.046	0.631±0.044	0.684±0.056
mnb	lemma	tfidf	1-2	0.636±0.034	0.627±0.033	0.679±0.048
mnb	lemma	bow	1-1	0.634±0.038	0.630±0.033	0.681±0.056
mnb	stem	tfidf	1-1	0.634±0.056	0.613±0.055	0.675±0.063
mnb	stem	bow	1-1	0.632±0.052	0.619±0.052	0.678±0.062
logreg	lemma	tf	1-1	0.632±0.054	0.637±0.049	0.677±0.057
mnb	lemma	tfidf	1-1	0.631±0.044	0.620±0.043	0.677±0.052
logreg	lemma	idf	1-1	0.630±0.041	0.629±0.037	0.675±0.052
logreg	lemma	tf	1-2	0.629±0.050	0.631±0.047	0.679±0.054
logreg	lemma	tfidf	1-1	0.627±0.060	0.635±0.050	0.677±0.057
logreg	lemma	idf	1-2	0.626±0.042	0.627±0.037	0.676±0.050
logreg	lemma	tfidf	1-2	0.625±0.041	0.630±0.038	0.682±0.053
mnb	none	tf	1-1	0.624±0.045	0.610±0.044	0.662±0.056
mnb	none	tfidf	1-1	0.623±0.036	0.602±0.037	0.654±0.053

Prikazano top 20 (po $F1$ klikbejt klase), nested 10-fold CV.

Najbolja varijanta je **multinomijalni naivni Bajes uz stemovanje i TF-IDF (1–2 grami)**, sa F1 na klikbejt klasi 0,646 i ROC-AUC 0,676. Razlike meu shemama ponderisanja su male: na kratkim naslovima IDF komponenta donosi ogranienu korist jer se rei retko ponavljaju, pa puko brojanje nije daleko od TF-IDF. Stemovanje pomae (smanjuje ratrkanost zbog morfologije srpskog), dok bigrami donose tek neznatno poboljanje. Glavni zakljuak: pristup zasnovan na vrei rei hvata povrinske leksike obrasce, ali teko prepoznaje suptilni klikbejt koji zavisi od konteksta i implikacije.

5.4 Enkoderski LLM (BERTi + mBERT)


Fino su podeena dva enkoderska modela — monolingvalni **BERTi** (za BCMS jezike) [5] i viejezini **mBERT** [3] — uz variranje broja epoha (2/3/4) i 10-struku validaciju.

Tabela 5: Enkoderski LLM — BERTi vs mBERT, varijante epoha.

Model	Epohe	F1 _{kb}	Acc.	P _{kb}	R _{kb}	AUC
bertic	2	0.681±0.042	0.680±0.034	0.678±0.036	0.688±0.069	0.760±0.036
bertic	3	0.703±0.034	0.704±0.035	0.707±0.047	0.703±0.050	0.785±0.036
bertic	4	0.703±0.034	0.702±0.035	0.703±0.039	0.704±0.038	0.788±0.030
mbert	2	0.651±0.042	0.664±0.034	0.678±0.040	0.629±0.063	0.736±0.042
mbert	3	0.690±0.042	0.687±0.041	0.685±0.045	0.699±0.058	0.753±0.042
mbert	4	0.682±0.041	0.691±0.036	0.703±0.042	0.664±0.054	0.755±0.038

10-slojna stratifikovana CV.

Mono > multi: BERTi nadmauje mBERT na svim metrikama, to potvrjuje da model treniran specifino za srpski (i srodne jezike) bolje hvata jezike nijanse. **Broj epoha:** 2 epohe su nedovoljne, dok 3–4 epohe daju najbolji i stabilan rezultat (F1 0,703, tanost 0,704, ROC-AUC do 0,788); dalje obuvanje ne donosi dobitak (vidi krivu uenja na Slici 2). U poreenju sa osnovnom linijom, ak i slabiji transformer (mBERT, F1 0,690) je +0,044 iznad najboljeg osnovnog modela, a razlika po ROC-AUC-u je jo vea (+0,11) — kontekstualni modeli znatno bolje razdvajaju klase.



Slika 2: Kriva uenja (F1/AUC u funkciji broja epoha) za enkoderske modele.

5.5 Dekoderski LLM (Claude)

Dekoderski (generativni) model **Claude (Haiku)** [1] primenjen je *bez fino podeavanja*, u reimu zero-shot, nad celim skupom.² Uporeene su dve prompt varijante — na srpskom (SR) i engleskom (EN) jeziku — obe sa definicijom klikbejta. Odgovori se keuju radi prekida/nastavka i da se ne plaa dvostruko.

Tabela 6: Dekoderski LLM (Claude) — SR vs EN, zero/few-shot.

Varijanta	Jezik	Shots	$F1_{kb}$	Acc.	P_{kb}	R_{kb}
en_zero_def	en	zero	0.715	0.691	0.664	0.775
sr_zero_def	sr	zero	0.710	0.695	0.676	0.748

Evaluacija na celom skupu.


Jezik upita (SR vs EN): razlika je zanemarljiva ($F1$ 0,710 naspram 0,715), uz neznatnu prednost engleskog prompta. **Snaga bez obuke:** model bez ijednog primera za obuku postie *najvii $F1$ na klikbejt klasi* u celom radu (0,715), blago iznad fino podeenog BERTia (0,703). Ogranienja su, meutim, sutinska: model vraa *tvrd* odluku 0/1, pa nema verovatnoa ni ROC-AUC-a; zavisi od plaenog API-ja i dnevnih ogranienja poziva; i nije lokalan. Evaluirane su dve prompt varijante (SR/EN, zero-shot, sa definicijom); few-shot i kalibracija ostaju za dalji rad.

5.6 Uporedni pregled svih modela

Tabela 7: Uporedni pregled — najbolja varijanta po tipu modela.

Najbolji po tipu	$F1_{kb}$	Acc.	AUC
Baseline (mnb, tfidf)	0.646 ± 0.045	0.622 ± 0.050	0.676 ± 0.059
Enkoderski (bertic)	0.703 ± 0.034	0.704 ± 0.035	0.785 ± 0.036
Enkoderski (mbert)	0.690 ± 0.042	0.687 ± 0.041	0.753 ± 0.042
Claude (en_zero_def)	0.715	0.691	

²U prijavi je naveden ChatGPT; postavka projekta izriito dozvoljava i druge dekoderske modele, pa je korien Claude (Haiku) kao funkcionalno ekvivalentan zatvoreni generativni model dostupan preko API-ja.



Slika 3: F1 (klikbejt klasa) najboljih varijanti po tipu modela.

Svi modeli nadmauju osnovnu liniju. Po *F1 na klikbejt klasi* vodi dekoderski Claude (0,715), ali po *tanosti* i kalibrisanim verovatnoama (ROC-AUC) najbolji je BERTi (0,704 / 0,788). Drugim reima, ne postoji jedinstveni pobednik: dekodera je najbolji kada nema podataka za obuku, a enkoder kada su potrebne pouzdane verovatnoe i lokalno, besplatno izvravanje.

6 Zakljuak

Pokazali smo da je detekcija klikbejt sportskih naslova na srpskom izvodljiva i da izbor modela zavisi od ogranijenja primene. **Za produkciju** preporuujemo **BERTi**: mali, besplatan, lokalni, daje kalibrisane verovatnoe (ROC-AUC 0,788) i najbolju tanost, uz najbolji odnos cena/kvalitet. **Kada nema podataka za obuku**, dekoderski model (Claude, zero-shot) je konkurentan i postie najvii F1 bez ijednog oznaenog primera, po cenu plaenog API-ja i odsustva verovatnoa. Osnovni modeli ostaju korisni kao brza, transparentna referenca.

Ogranijenja. Skup je relativno mali (2200), iz jednog domena (sport) i sa jednog izvora (SportKlub); dekodera daje samo tvrde labele (bez AUC-a); evaluirane su dve prompt varijante. **Dalji rad.** Vie domena i izvora, vei skup, few-shot prompting i kalibracija dekodera, ansambl (BERTi + dekodera) i analiza tipova greaka po pod-tipovima klikbejta (KJ/PV/EN/SF).

Literatura

- [1] Anthropic. The Claude 3 model family: Opus, Sonnet, Haiku. *Anthropic Technical Report*, 2024.
- [2] Abhijnan Chakraborty, Bhargavi Paranjape, Sourya Kakarla, and Niloy Ganguly. Stop click-bait: Detecting and preventing clickbaits in online news media. In *Proceedings of the IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM)*, 2016.
- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, 2019.

- [4] Nikola Ljubešić and Kaja Dobrovoljc. CLASSLA-StanfordNLP: A tool for the processing of croatian, serbian and slovenian. In *Proceedings of the 7th Workshop on Balto-Slavic Natural Language Processing (BSNLP)*, 2019.
- [5] Nikola Ljubešić and Davor Lauc. BERTi – the transformer language model for bosnian, croatian, montenegrin and serbian. In *Proceedings of the 8th Workshop on Balto-Slavic Natural Language Processing (BSNLP)*, 2021.
- [6] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [7] Martin Potthast, Sebastian Köpsel, Benno Stein, and Matthias Hagen. Clickbait detection. *Advances in Information Retrieval (ECIR)*, 2016.